

Cross-Domain descriptor learning for 2D-3D matching on geological outcrops

Marco Repetto Jara

marco.repetto@usm.cl

Universidad Técnica Federico Santa María
Valparaíso, Chile

Resumen

Este trabajo aborda la brecha entre la información visual (2D) y la geométrica (3D) en el contexto de afloramientos geológicos para la estimación de la pose de un observador. La asimetría de información y la estocasticidad lumínica en este entorno presentan un desafío crítico: mientras que la semántica visual es inestable ante cambios de iluminación (sensores pasivos bajo BRDF variable), la geometría estructural capturada por sensores activos (como LiDAR) es invariante pero discreta. Proponemos un enfoque que integra ambos dominios mediante el uso de descriptores semánticos densos y mecanismos de atención cruzada, permitiendo que la certidumbre estructural actúe como una máscara de contexto sobre el espacio visual. Este método busca reducir la ambigüedad en el matching 2D-3D desplazando el aprendizaje hacia la jerarquía de discontinuidades estructurales geológicas invariantes.

CCS Concepts

• **Computing methodologies** → **Reconstruction**; *Neural networks*.

Palabras claves

Matching 2D-3D, Descriptores Cross-Domain, Geología, Estimación de Pose, Deep Learning

ACM Reference Format:

Marco Repetto Jara. 2026. Cross-Domain descriptor learning for 2D-3D matching on geological outcrops. In *Proceedings of Minería de Datos y Reconocimiento de Patrones (INF577-2026)*. ACM, New York, NY, USA, 7 pages.

1 Introducción

La estimación precisa de la pose de un observador dentro de un modelo 3D geológico es fundamental para la interpretación estructural y la exploración de recursos. Este problema puede describirse como una asimetría física: el LiDAR es un **sensor activo** que captura geometría pura, mientras que la cámara es un **sensor pasivo** cuya salida depende de las condiciones de iluminación y las propiedades visuales de la superficie rocosa. Para obtener la estimación de pose final, es necesario establecer correspondencias precisas entre puntos de la imagen y puntos en el modelo 3D para su procesamiento en un algoritmo de Perspectiva de n Puntos (PnP) [Lepetit et al. 2009], el cual calcula la posición y orientación final a partir de dichos pares de puntos. Este trabajo se enfoca en

resolver este paso intermedio crítico mediante un enfoque de aprendizaje *cross-domain* para la extracción de descriptores semánticos congruentes entre ambos dominios. Al mapear la imagen y el modelo al mismo espacio latente, facilitamos la identificación de las correspondencias necesarias para la localización.

Nuestra investigación define el problema central como una **asimetría de información y estocasticidad lumínica**. La brecha reside en que la semántica visual es inestable ante cambios de iluminación, mientras que la geometría estructural es invariante pero discreta. Para abordar esto, introducimos un **Inductive Bias Geológico**, tratando la nube de puntos como una estructura con jerarquía fractal que incorpora la orientación de las capas y la continuidad de las estructuras geológicas.

El sistema debe reconciliar la percepción geométrica con la visual, utilizando la primera para proporcionar el contexto necesario que resuelva la ambigüedad de la segunda. De acuerdo con [Lai et al. 2022], la brecha visual-geométrica requiere de un aprendizaje conjunto de descriptores locales que sean robustos a estas diferencias de dominio. Al resolver este desafío de alineamiento 2D-3D en geometrías repetitivas, el presente trabajo habilita un impacto directo en la automatización del mapeo estructural para la minería a cielo abierto, optimizando el análisis de estabilidad de taludes y mitigando riesgos operativos. Más allá de su aplicación minera, esta investigación ofrece una contribución fundamental al estado del arte en SLAM (Simultaneous Localization and Mapping) visual e inter-dominio para entornos naturales y no estructurados. Al independizar la localización visual de primitivas geométricas humanas (esquinas, bordes rectos), la arquitectura propuesta sienta bases para sistemas de navegación autónoma en robótica planetaria y exploración de ambientes extremos carentes de textura.

2 Trabajo Relacionado

El desafío del alineamiento entre imágenes 2D y nubes de puntos 3D ha sido abordado históricamente mediante la búsqueda de invariantes que reduzcan la asimetría informativa entre ambos dominios. En esta sección, revisamos la literatura actual, analizando cómo el funcionamiento interno de las arquitecturas de aprendizaje profundo interactúa con la física y la geometría de los afloramientos geológicos. Nuestro análisis transita desde los baselines de *matching* local basados en intensidad hasta los modelos fundacionales y las

redes de procesamiento geométrico, destacando sus limitaciones inherentes ante la varianza lumínica y la repetición estructural.

2.1 Local Matching

En la última década, el campo del emparejamiento local ha transitado desde descriptores diseñados manualmente hacia arquitecturas de aprendizaje profundo de extremo a extremo. Uno de los exponentes más relevantes es *SuperPoint* [DeTone et al. 2018], el cual propone un marco de entrenamiento autosupervisado que computa conjuntamente ubicaciones de puntos de interés y descriptores a nivel de píxel en una sola pasada hacia adelante.

Su innovación radica en la técnica de *Homographic Adaptation*, un procedimiento de autosupervisión diseñado para aumentar la repetibilidad del detector en imágenes del mundo real. Esta técnica emplea transformaciones homográficas, matrices matemáticas de 3×3 que modelan la relación geométrica entre dos proyecciones de una misma superficie plana (como rotaciones, cambios de escala y distorsiones de perspectiva). Al aplicar múltiples homografías aleatorias sobre una imagen no etiquetada, la red genera un conjunto de respuestas de detección que luego son “des-proyectadas” a su forma original y agregadas. Este proceso permite identificar un consenso de puntos estables a través de diferentes puntos de vista, creando etiquetas de verdad de campo sintéticas (pseudo-etiquetas) que guían el aprendizaje sin intervención humana.

A pesar de su robustez en entornos urbanos, arquitecturas como *SuperPoint* presentan limitaciones críticas al ser aplicadas en afloramientos geológicos. El problema reside en su dependencia de los gradientes de intensidad lumínica para detectar esquinas o bordes. Esta detección es vulnerable a la varianza de la *Bidirectional Reflectance Distribution Function* (BRDF) del afloramiento. La BRDF es una función física que describe cuánta luz se refleja en una superficie dependiendo del ángulo desde el que se ilumina y desde el que se observa. En las rocas, factores como la rugosidad a micro-escala y la composición mineral provocan que la BRDF cambie drásticamente con la posición del sol. Como consecuencia, las variaciones de brillo en los píxeles pueden generar “bordes” visuales que no existen en la estructura física, confundiendo al detector. Dado que la cámara es un sensor pasivo, la apariencia visual de una estructura rocosa es estocástica y depende del entorno lumínico. Un detector basado en intensidades visuales puede identificar puntos de interés que corresponden a sombras transitorias en lugar de discontinuidades físicas reales (como fracturas o planos de falla).

Para mitigar los errores en la correspondencia de estos detectores locales, arquitecturas de *matching* posteriores como *SuperGlue* [Sarlin et al. 2020] incorporaron Redes Neuronales de Grafos (GNN) y mecanismos de atención cruzada para resolver asignaciones considerando el contexto espacial. Si bien *SuperGlue* mejora significativamente el rechazo de correspondencias anómalas (*outliers*) al razonar sobre la geometría

relativa de los puntos en 2D, su rendimiento está estrictamente acotado por la calidad de las detecciones iniciales. Al depender de descriptores puramente visuales, el *matching* continúa fallando en entornos de repetición fractal o sedimentaria, donde la red es incapaz de desambiguar texturas idénticas sin un anclaje externo. Esta limitación inherente demuestra que la incorporación de atención geométrica puramente bidimensional es insuficiente, justificando la necesidad de desplazar el aprendizaje hacia la jerarquía de discontinuidades geométrica 3D mediante mecanismos *cross-domain* [Xu et al. 2025].

2.2 DINOv2 como Puente Cognitivo

La extracción de descriptores visuales robustos es fundamental para cerrar la brecha entre la imagen 2D y la geometría 3D. En este trabajo, se propone el uso de DINOv2 [Oquab et al. 2024] como columna vertebral para la obtención de representaciones semánticas densas. A diferencia de modelos supervisados o alineados con texto como CLIP [Radford et al. 2021], DINOv2 se entrena mediante una combinación de destilación de conocimiento a nivel de imagen y modelado de parches enmascarados (iBOT) [Zhou et al. 2022]. La destilación a nivel de imagen permite que el modelo estudiante aprenda invarianza semántica global al replicar las representaciones de un profesor con *momentum*. Complementariamente, el objetivo de iBOT fuerza al Vision Transformer (ViT) a reconstruir parches enmascarados a partir de su contexto local, lo que induce una comprensión profunda de las estructuras granulares. Esta arquitectura permite que cada *token* de parche funcione como un descriptor denso con una alta coherencia espacial y sensibilidad local, propiedades críticas para el *matching* en superficies irregulares donde los métodos puramente locales suelen fallar por falta de contexto.

Sin embargo, los modelos fundacionales pre-entrenados en conjuntos de datos masivos (LVD-142M) presentan un sesgo inherente hacia las bajas frecuencias espaciales, priorizando la segmentación de objetos y siluetas sobre el detalle de textura fina. En el contexto de afloramientos geológicos, la información discriminativa reside precisamente en la alta frecuencia: la micro-rugosidad de las superficies de falla, la estratificación fractal y la anisotropía de las fracturas.

Para mitigar este sesgo sin incurrir en el olvido catastrófico de las capacidades de generalización del modelo, proponemos la integración de *Visual Adapters* mediante técnicas de Ajuste Fino Eficiente en Parámetros (PEFT) [Chen et al. 2022; Houlsby et al. 2019]. Específicamente, estos cuellos de botella se inyectan en paralelo a la capa *Feed-Forward* (MLP) de cada bloque Transformer. Este diseño asegura que las capas de autoatención preentrenadas por iBOT permanezcan inalteradas, reteniendo el *prior* visual global, mientras los adaptadores sintonizan los descriptores hacia la jerarquía de discontinuidades estructurales del dominio geológico. La decisión de utilizar DINOv2 sobre el ajuste fino de modelos especializados como SuperPoint [DeTone et al. 2018] radica en la capacidad de representación de los modelos fundacionales. Mientras que SuperPoint está optimizado para geometrías urbanas y detección de esquinas simples, DINOv2 posee un

prior visual mucho más rico y escalable. Al inyectar este sesgo inductivo mediante adaptadores, el modelo transita de una comprensión puramente visual-estocástica a una representación que prioriza las invariantes geométricas, actuando así como un puente cognitivo que facilita el alineamiento con la topología capturada por sensores activos como el LiDAR.

2.3 Geometría y Topología

La representación de la estructura 3D en afloramientos geológicos requiere un paradigma que trascienda la mera acumulación de coordenadas espaciales. Baselines clásicos como PointNet [Qi et al. 2017] introdujeron la capacidad de procesar nubes de puntos de forma directa mediante funciones simétricas; sin embargo, su arquitectura se basa fundamentalmente en perceptrones multicapa (MLP) compartidos que operan sobre cada punto de forma aislada. Al carecer de mecanismos de convolución o agregación local previos a la función de pooling global (usualmente *max-pooling*), PointNet trata la nube como una “bolsa de elementos” independientes, ignorando la correlación geométrica entre puntos vecinos. Esta falta de contexto local es particularmente problemática en geología, donde la identidad de un punto (ej. parte de una superficie de falla o un contacto estratigráfico) está definida intrínsecamente por su relación geométrica y de orientación con el entorno circundante.

Para superar esta limitación, adoptamos los principios de *Dynamic Graph CNN* (DGCNN) [Wang et al. 2019]. A diferencia de PointNet, DGCNN construye grafos dinámicos para capturar estructuras locales en el espacio de características, permitiendo que la red extraiga información topológica y agrupe puntos basándose en sus relaciones geométricas relativas y diferencias vectoriales.

La naturaleza dinámica de este enfoque radica en que el grafo de vecindad no se mantiene estático; se recalcula en el espacio de características de cada capa. Esto permite que la red agrupe semánticamente puntos que, aunque distantes en el espacio euclidiano original, comparten propiedades estructurales similares en el espacio latente. En el contexto de afloramientos, esta capacidad es crítica para mantener la conectividad de una unidad geológica. Para abordar específicamente la escala fractal de las rocas, el vecindario de puntos se analiza mediante un enfoque multi-escala con radios de agregación progresivamente mayores. Al capturar las adyacencias topográficas con dilatación estructural, se codifica la jerarquía completa de la roca (desde la micro-rugosidad de una falla hasta la estratigrafía macroscópica), proporcionando una base robusta para el mecanismo de atención cruzada 2D-3D que describiremos en la sección de Metodología. De este modo, la nube de puntos deja de ser una masa amorfa para convertirse en una estructura con jerarquía y continuidad geológica.

2.4 Metric Learning Adaptativo

El alineamiento de características en el espacio compartido 2D-3D se formula como un problema de aprendizaje de métricas (*Metric Learning*), cuyo objetivo es minimizar la

distancia entre descriptores correspondientes y maximizarla entre pares disímiles en un espacio latente común. Sin embargo, los afloramientos geológicos presentan un desafío crítico: la redundancia estructural. Fenómenos como los patrones de fracturamiento repetitivos o la alternancia rítmica de capas sedimentarias generan texturas visuales y geometrías casi idénticas en múltiples ubicaciones, lo que induce ambigüedad y dificulta la convergencia de la red.

Tradicionalmente, este problema se ha abordado mediante la *Triplet Loss* [Schroff et al. 2015]. No obstante, la *Triplet Loss* aplica un gradiente uniforme a todos los pares dentro de un margen fijo, lo que limita su capacidad para diferenciar casos extremadamente similares en dominios con alta repetición fractal, generando un sobreajuste a texturas estocásticas.

Para abordar esta limitación, es fundamental utilizar funciones de pérdida adaptativas como la *Circle Loss* [Sun et al. 2020; Xu et al. 2025]. A diferencia de la aproximación rígida de la *Triplet Loss*, la *Circle Loss* otorga mayor importancia a los “casos difíciles” mediante una frontera de decisión flexible y un mecanismo de ponderación dinámica (*Self-paced Weighting*). Este enfoque actúa como un currículo de aprendizaje: disminuye la presión de optimización sobre pares de correspondencia ya consolidados y amplifica el gradiente en las regiones más ambiguas. Al regular la influencia de los pares más conflictivos en las etapas tempranas, el aprendizaje adaptativo asegura que el modelo converja hacia las invariantes estructurales fundamentales del afloramiento, evitando el colapso ante el ruido visual de superficies idénticas. De este modo, el aprendizaje de métricas se transforma en un proceso robusto y físicamente coherente con la naturaleza repetitiva del dominio geológico.

2.5 Descriptores Cross-Domain 2D-3D y Localización

El alineamiento directo de imágenes a nubes de puntos LiDAR ha cobrado relevancia mediante arquitecturas que mapean ambas modalidades a un espacio latente común. Arquitecturas pioneras como *LCD* [Pham et al. 2020] propusieron autoencoders duales para aprender descriptores compartidos. Sin embargo, su enfoque carece de mecanismos de atención local y asume una correspondencia uniforme que falla en presencia de texturas geológicas repetitivas.

Por otro lado, métodos como *2D3D-MVPNet* [Lai et al. 2022] proyectan subvolúmenes 3D en múltiples planos 2D para extraer descriptores análogos empleando redes convolucionales estándar. Si bien esto mitiga la asimetría dimensional, la compresión de una topología tridimensional $\mathbf{p} \in \mathbb{R}^3$ a un hiperplano bidimensional provoca pérdida de inyectividad geométrica. En afloramientos de alta rugosidad fractal, esta proyección colapsa las normales de superficie yuxtapuestas, destruyendo la jerarquía de discontinuidades y haciendo que texturas no coplanares parezcan idénticas en el plano proyectado, lo que induce errores catastróficos en el matching. En contraste, *EP2P-Loc* [M. Kim et al. 2023] propone localización end-to-end omitiendo detectores de keypoints mediante clasificación de parches y PnP diferenciable. A pesar

de su efectividad en entornos viales (KITTI), la suposición de regularidad espacial urbana limita su transferibilidad a macizos rocosos con geometría fractal altamente irregular.

Recientemente, el trabajo de [Kou et al. 2025] en la localización del rover marciano Zhurong aborda el matching en terrenos desérticos de textura pobre utilizando priors 3D aproximados (GNC dead-reckoning) para restringir el dominio de búsqueda homográfica. Esto demuestra que la incorporación de restricciones geométricas externas es clave para resolver la ambigüedad en entornos naturales, validando el diseño de nuestra propuesta GSCA.

2.6 Pregunta de Investigación e Hipótesis

La revisión de la literatura evidencia que los métodos actuales de *matching* fracasan ante la repetición estructural de los afloramientos geológicos porque confían exclusivamente en descriptores visuales estocásticos que colapsan ante variaciones lumínicas. A partir de esta asimetría física entre los sensores pasivos (cámara) y activos (LiDAR), formulamos la siguiente pregunta de investigación:

PREGUNTA DE INVESTIGACIÓN 1. *¿De qué manera es posible estimar con precisión sub-métrica la pose de un observador en un afloramiento geológico a partir de una única imagen monocolor RGB y un prior ruidoso, mitigando la ambigüedad de patrones sedimentarios cíclicos y la estocasticidad lumínica mediante la inyección de restricciones topológicas tridimensionales?*

HIPÓTESIS 1. *La ambigüedad en el matching 2D-3D de afloramientos geológicos se reduce significativamente al desplazar el aprendizaje desde la apariencia visual estocástica hacia la jerarquía de discontinuidades estructurales invariantes, utilizando una arquitectura de Atención Cruzada que proyecta las normales y adyacencias topográficas (3D) como máscara de contexto sobre el espacio visual (2D), optimizado mediante una Circle Loss regulada para evitar el colapso en entornos de alta repetición estructural.*

3 Metodología y Formulación del Problema

El problema de la estimación de pose en entornos geológicos se formula como el alineamiento de dos *latent manifolds* provenientes de dominios físicamente asimétricos. Definimos $\mathcal{I}$ como el espacio de imágenes RGB (capturadas por un sensor pasivo) y $\mathcal{M}$ como la malla o nube de puntos estructural 3D (capturada por un sensor activo). Nuestra arquitectura busca aprender los mapeos no lineales $F: \mathcal{I} \rightarrow \mathcal{Z}$ y $G: \mathcal{M} \rightarrow \mathcal{Z}$, donde $\mathcal{Z}$ representa un espacio latente común de alta dimensionalidad donde las correspondencias semánticas y geométricas son congruentes. Es imperativo notar que, a diferencia de los *smooth manifolds* tratados habitualmente en visión computacional, la superficie de un afloramiento geológico es intrínsecamente discreta, rugosa y fracturada. En este contexto, la rugosidad fractal y las discontinuidades estructurales no son ruido, sino que constituyen las coordenadas fundamentales de la variedad geológica.

Para resolver la inestabilidad de la apariencia visual frente a cambios de iluminación, la arquitectura GSCA (*Geo-Structural*

Cross-Attention) introduce un mecanismo de Atención Cruzada (*Cross-Attention*). Este operador actúa como un puente cognitivo que utiliza la certidumbre de la estructura geométrica 3D como una máscara de contexto confiable que guía y filtra la extracción de características en el espacio visual 2D.




Figura 1: Arquitectura GSCA propuesta. La estructura 3D guía la extracción de descriptores visuales mediante una máscara topológica.

A continuación, detallamos la formulación matemática de los componentes principales de nuestra arquitectura.

3.1 Extracción de Características

Rama Visual (2D): Sea $\mathbf{f}_i^{2D} = F(I)_i \in \mathbb{R}^C$ el descriptor semántico denso del píxel i . Para recuperar la resolución espacial densa a partir de los parches base de DINOv2 (típicamente de 14×14 píxeles), la arquitectura F acopla una red *Feature Pyramid Network* (FPN) ligera sobre las capas del Transformer, inspirado en la arquitectura *Dense Prediction Transformers* (DPT) [Ranftl et al. 2021]. Adicionalmente, el modelo DINOv2 incorpora *Visual Adapters* para ajustar los descriptores al dominio geológico sin sufrir de olvido catastrófico.

Rama Geométrica (3D): Sea $\mathbf{f}_j^{3D} = G(M)_j \in \mathbb{R}^C$ el descriptor geométrico del punto 3D j . Para extraer características topológicas locales, $G(M)$ emplea el operador *Edge-Conv* basado en DGCNN [Wang et al. 2019]. Para cada punto $p_i = (x_i, y_i, z_i)$ se construye un grafo dirigido $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ con sus k -vecinos más cercanos. El operador define características de arista como $e_{ij} = h_\Theta(p_i, p_j - p_i)$, donde h_Θ es una función no lineal con parámetros aprendibles Θ . Al codificar explícitamente la diferencia vectorial $(p_j - p_i)$, se captura la topología

local. Finalmente, las características se agregan mediante una función simétrica $p'_i = \max_{j:(i,j) \in \mathcal{E}} e_{ij}$, propagando la información estructural del macizo a través de la red.

3.2 Cross-Attention Estructural

Para proyectar la nube de puntos en el plano de la imagen, utilizamos la pose inicial estimada $\mathbf{T}_{prior} = [\mathbf{R}_{prior} | \mathbf{t}_{prior}] \in SE(3)$ y la matriz de calibración intrínseca de la cámara $\mathbf{K}$:

$$\lambda_j \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix} = \mathbf{K} (\mathbf{R}_{prior} \mathbf{p}_j + \mathbf{t}_{prior}) \quad (1)$$

donde $\mathbf{p}_j = (x_j, y_j, z_j)^T$ es la coordenada física del punto, λ_j es la profundidad proyectada, y (u_j, v_j) es su proyección en la imagen.

El módulo de Atención Cruzada calcula la afinidad entre los mapas de descriptores densos utilizando proyecciones lineales $\mathbf{W}_q$, $\mathbf{W}_k$, y $\mathbf{W}_v$. Definimos las consultas $\mathbf{Q} \in \mathbb{R}^{HW \times C}$ derivadas de $F(I)$ y las claves $\mathbf{K} \in \mathbb{R}^{N \times C}$ derivadas de $G(M)$. La matriz de atención cruzada atenuada por la estructura física del afloramiento se define como:

$$\mathbf{A}_{cross} = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{C}} + \mathbf{M}_{geo} \right) \quad (2)$$

donde $\mathbf{M}_{geo} \in \mathbb{R}^{HW \times N}$ es la máscara estructural. Esta máscara penaliza correspondencias inverosímiles basándose en la distancia euclidiana proyectada y la orientación de las normales de la superficie:

$$\mathbf{M}_{geo}(i, j) = \begin{cases} 0 & \text{si } \|(u_i, v_i) - (u_j, v_j)\|_2 \leq \delta \text{ y } \langle \mathbf{n}_i, \mathbf{n}_j \rangle \geq \tau \\ -\infty & \text{en caso contrario} \end{cases} \quad (3)$$

donde $\mathbf{n}_i$ y $\mathbf{n}_j$ representan las normales estimadas en la imagen y en la nube 3D, respectivamente. Las normales 2D $\mathbf{n}_i$ son extraídas a partir de un módulo de visión independiente del presente proyecto. Para efectos de esta investigación, asumimos que dichas normales están disponibles como entradas pre-calculadas y que su distribución de ruido puede modelarse mediante un error Gaussiano. Este error residual se mitiga gracias a que la evaluación de coplanaridad en la máscara actúa como un filtro suave mediante el umbral τ . El parámetro δ es el radio de tolerancia de búsqueda derivado de la incertidumbre del prior de pose ($Error < 1m$). De esta manera, $\mathbf{M}_{geo}$ penaliza correspondencias inverosímiles tolerando el ruido estocástico de las normales en entornos de alta rugosidad.

Una vez filtradas las características por el mapa de atención cruzada, el emparejamiento denso se realiza mediante una búsqueda de vecinos más cercanos mutuos (*Mutual Nearest Neighbors*, MNN). Se establece una correspondencia entre el descriptor visual i y el descriptor geométrico j si y solo si:

$$j = \arg \max_k \text{sim}(\mathbf{f}_i^{2D}, \mathbf{f}_k^{3D}) \text{ y } i = \arg \max_l \text{sim}(\mathbf{f}_l^{2D}, \mathbf{f}_j^{3D}) \quad (4)$$

donde $\text{sim}(a, b) = \frac{a \cdot b}{\|a\| \|b\|}$ representa la similitud coseno entre los descriptores.

3.3 Función de Pérdida Global y Entrenamiento

La arquitectura GSCA se entrena de forma *end-to-end* minimizando una función de pérdida métrica adaptativa calculada sobre los pares correspondientes definidos por el MNN. Para superar el colapso de los gradientes uniformes frente a patrones geológicos repetitivos, utilizamos la *Circle Loss* [Sun et al. 2020]:

$$L_{circle} = \log \left(1 + \sum_{j=1}^n e^{\gamma \alpha_n^j (s_n^j - \Delta_n)} \sum_{i=1}^m e^{-\gamma \alpha_p^i (s_p^i - \Delta_p)} \right) \quad (5)$$

donde s_p^i y s_n^j son las similitudes coseno calculadas sobre los vectores de características positivos y negativos respectivamente, γ es un factor de escala y Δ representa los márgenes.

El mecanismo de *Self-paced Weighting* regula dinámicamente los factores de ponderación α para cada par:

$$\alpha_p^i = [O_p - s_p^i]_+, \quad \alpha_n^j = [s_n^j - O_n]_+ \quad (6)$$

donde O_p y O_n son los objetivos de convergencia óptimos. Este enfoque penaliza en gran medida a los “casos difíciles” (superficies casi idénticas que confunden al alineamiento) mientras relaja la presión de optimización sobre las correspondencias ya establecidas. Así, el objetivo global empuja a los extractores F y G a converger de forma sincrónica hacia las discontinuidades estructurales invariantes del macizo rocoso.

4 Viabilidad, Datos y Adaptabilidad

La implementación de la arquitectura propuesta enfrenta dos desafíos críticos: la especialización de modelos fundacionales masivos y la validación de mecanismos de atención en entornos con alta varianza estocástica. Esta sección detalla la estrategia para abordar estas limitantes mediante eficiencia paramétrica y entornos de validación controlada.

4.1 Eficiencia Paramétrica y Adaptadores Visuales

El uso de *DINOv2* como extractor de características ofrece una base semántica robusta, pero su ajuste fino (*fine-tuning*) integral en el dominio geológico presenta el riesgo de **olvido catastrófico** (*catastrophic forgetting*), donde el modelo pierde su capacidad de generalización previa al sobreajustarse a las texturas fractales de los afloramientos.

Para mitigar esto, se propone el uso de **Visual Adapters** [Houlsby et al. 2019]. Esta técnica de *Parameter-Efficient Fine-Tuning* (PEFT) consiste en inyectar capas de cuello de botella (*bottleneck layers*) ligeras entre los bloques del transformador congelado. Específicamente, para cada bloque Transformer l , introducimos un adaptador paralelo al perceptrón multicapa (MLP) definido como $\text{Adapter}(x) = \sigma(x \mathbf{W}_{down}) \mathbf{W}_{up}$, donde $\mathbf{W}_{down} \in \mathbb{R}^{d \times r}$, $\mathbf{W}_{up} \in \mathbb{R}^{r \times d}$ con un rango intrínseco $r \ll d$ y σ como función de activación no lineal. El **inductive bias geológico** se inyecta exclusivamente en estos adaptadores, permitiendo que la red aprenda la jerarquía de discontinuidades y la anisotropía estructural sin alterar los pesos fundamentales del modelo pre-entrenado.

Esto no solo preserva la coherencia espacial de DINOv2, sino que reduce drásticamente los requerimientos de memoria y cómputo, haciendo viable el entrenamiento en hardware convencional.

4.2 Entornos de Validación: El Laboratorio Sintético

La validación de la hipótesis central es compleja en datos reales debido a la imposibilidad de controlar la **BRDF** (Bidirectional Reflectance Distribution Function) del afloramiento y la falta de una verdad de campo (*ground truth*) de pose con precisión sub-centimétrica.

Se propone un pipeline de generación de datos en **Unity/OpenGL** que actúe como un laboratorio de validación controlada. Este entorno permite:

1. **Aislamiento de variables:** Manipular sistemáticamente la iluminación solar y condiciones atmosféricas para evaluar la robustez del mecanismo de atención ante la estocasticidad lumínica.
2. **Verdad de campo absoluta:** Obtener métricas de error de pose (R, t) sin la incertidumbre inherente a los sistemas GPS/IMU en terreno.
3. **Mapeo de Normales:** Generar mapas de normales y adyacencias topográficas exactas para supervisar el aprendizaje de la jerarquía de discontinuidades.

Este enfoque pedagógico asegura que la arquitectura GSCA sea validada en un entorno donde el único factor de éxito sea su capacidad de alineamiento estructural, antes de transicionar a la complejidad y ruido de los datos de campo.

4.3 Métricas y Baselines

Para validar cuantitativamente la superioridad de la arquitectura GSCA, el desempeño se comparará contra los siguientes algoritmos del estado del arte:

- **Baselines de Local Matching:** SuperPoint + SuperGlue acoplado a EPnP, evaluando el límite de desempeño de descriptores puramente visuales ante geometría repetitiva.
- **Baselines Cross-Domain:** 2D3D-MVPNet y LCD, para evaluar mejoras frente a enfoques previos de aprendizaje de métricas inter-dominio.
- **Baseline End-to-End:** EP2P-Loc, representando el estado del arte en localización directa sin detección de keypoints.

El éxito de la estimación de 6-DoF se medirá utilizando métricas estandarizadas en localización visual:

- **AUC del Error de Pose:** Se calculará el Área Bajo la Curva de los errores de pose bajo los umbrales estrictos de (5cm, 1°), (10cm, 5°), y (20cm, 10°).
- **Calidad de Correspondencias:** Ratio de *inliers* validados por RANSAC y error de reproyección (en píxeles) tras la optimización geométrica.

4.4 Acceso a Datos Reales y Estrategia Sim-to-Real

Para consolidar la viabilidad del proyecto más allá de la simulación, se ha confirmado la accesibilidad a conjuntos de datos de afloramientos reales mediante repositorios abiertos de geociencias. Utilizaremos nubes de puntos LiDAR y modelos de fotogrametría digital de la plataforma **Svalbox** [Senger et al. 2022] y del repositorio académico **eRock**. En particular, priorizaremos modelos tridimensionales de bancos geológicos de minas a cielo abierto, capturando proyecciones hacia el banco desde un ángulo oblicuo a una distancia de 20 a 30 metros. Asimismo, se integrarán datos topográficos de **OpenTopography**.

Para prevenir una brecha de dominio geométrica (*geometric domain gap*), las nubes de puntos extraídas de Unity serán sometidas a degradación estocástica, incluyendo la inyección de ruido Gaussiano en las coordenadas espaciales y submuestreo aleatorio para emular la densidad irregular de los escaneos LiDAR reales. Durante la generación de imágenes sintéticas, variaremos estocásticamente: (a) el ángulo de incidencia solar (acimut y elevación de 0° a 360°), (b) la rugosidad física de la roca mediante mapas de normales perturbados por ruido fractal, y (c) la reflectancia difusa (albedo) simulando meteorización mineral.

Se trabajará con una muestra de 10,000 imágenes sintéticas para entrenamiento y validación. La arquitectura GSCA será entrenada en un entorno simulado y evaluada directamente sobre los *splits* de prueba reales de Svalbox y eRock.

Asimismo, durante la validación experimental, el prior de pose T_{prior} se sintetizará aplicando una perturbación aleatoria a la matriz de transformación *ground truth*, muestreando un error de traslación uniforme $\Delta t \sim \mathcal{U}(-1m, 1m)$ y un error de rotación ΔR parametrizado en ángulos de Euler con magnitud máxima de 5°.

Al forzar a los *Visual Adapters* a extraer descriptores invariantes ante estas perturbaciones sintéticas extremas, garantizamos que el mecanismo de atención cruzada se ancle a la jerarquía de discontinuidades físicas del afloramiento. Consecuentemente, el modelo será entrenado y validado exclusivamente en el entorno simulado y se evaluará directamente sobre los *splits* de prueba reales de Svalbox y eRock, sin requerir *fine-tuning* adicional (Zero-Shot), demostrando la generalización pura de nuestro inductive bias geológico.

5 Declaración de Uso de IA

Este documento fue elaborado con la asistencia de Gemini. La herramienta se utilizó para refinar la hipótesis de investigación y estructurar el hilo conductor del artículo siguiendo el formato ACM. Se utilizó NotebookLM y Perplexity para la búsqueda de fuentes. Además, se utilizó NotebookLM para la consulta de las fuentes y como asistente para la comprensión de las mismas. El autor verificó manualmente todas las afirmaciones técnicas y las referencias bibliográficas.

Referencias

- Shoufa Chen, Chongjian Ge, Zhan Tong, Jinyu Wang, Yibo Song, Jiemin Wang y Ping Luo. 2022. “AdaptFormer: Adapting Vision Transformers for Scalable Visual Recognition”. En: *Advances in Neural Information Processing Systems*.
- Daniel DeTone, Tomasz Malisiewicz y Andrew Rabinovich. Jun. de 2018. “SuperPoint: Self-Supervised Interest Point Detection and Description”. en. En: IEEE, Salt Lake City, UT, USA, (jun. de 2018), 337-33712. ISBN: 978-1-5386-6100-0. doi:10.1109/CVPRW.2018.00060.
- Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski y Bruna Morrone. 2019. “Parameter-Efficient Transfer Learning for NLP”. en.
- Minjung Kim, Junseo Koo y Gunhee Kim. Oct. de 2023. “EP2P-Loc: End-to-End 3D Point to 2D Pixel Localization for Large-Scale Visual Localization”. en. En: *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, Paris, France, (oct. de 2023), 21470-21480. ISBN: 979-8-3503-0718-4. doi:10.1109/ICCV51070.2023.01968.
- Yuke Kou, Wenhui Wan, Kaichang Di, Zhaoqin Liu, Man Peng, Yexin Wang, Bin Xie, Biao Wang y Chenxu Zhao. 2025. “Cross-Site Visual Localization of Zhurong Mars Rover Based on Self-Supervised Key-point Extraction and Robust Matching”. en. *IEEE Transactions on Geoscience and Remote Sensing*, 63, 1-20. doi:10.1109/TGRS.2025.3541152.
- Baiqi Lai, WeiQuan Liu, Cheng Wang, Xiaoliang Fan, Yangbin Lin, Xuesheng Bian, Shangbin Wu, Ming Cheng y Jonathan Li. Sep. de 2022. “2D3D-MVPNet: Learning cross-domain feature descriptors for 2D-3D matching based on multi-view projections of point clouds”. en. *Applied Intelligence*, 52, 12, (sep. de 2022), 14178-14193. doi:10.1007/s10489-022-03372-z.
- Vincent Lepetit, Francesc Moreno-Noguer y Pascal Fua. Feb. de 2009. “EPnP: An Accurate O(n) Solution to the PnP Problem”. en. *International Journal of Computer Vision*, 81, 2, (feb. de 2009), 155-166. doi:10.1007/s11263-008-0152-6.
- Maxime Oquab et al.. 2024. “DINOv2: Learning Robust Visual Features without Supervision”. en.
- Quang-Hieu Pham, Mikaela Angelina Uy, Binh-Son Hua, Duc Thanh Nguyen, Gemma Roig y Sai-Kit Yeung. Abr. de 2020. “LCD: Learned Cross-Domain Descriptors for 2D-3D Matching”. en. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34, 07, (abr. de 2020), 11856-11864. doi:10.1609/aaai.v34i07.6859.
- Charles R. Qi, Hao Su, Kaichun Mo y Leonidas J. Guibas. 2017. “PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 652-660.
- Alec Radford et al.. 2021. “Learning Transferable Visual Models From Natural Language Supervision”. En: *Proceedings of the 38th International Conference on Machine Learning*, 8748-8763.
- René Ranftl, Alexey Bochkovskiy y Vladlen Koltun. 2021. “Vision transformers for dense prediction”. En: *Proceedings of the IEEE/CVF international conference on computer vision*, 12179-12188.
- Paul-Edouard Sarlin, Daniel DeTone, Tomasz Malisiewicz y Andrew Rabinovich. Jun. de 2020. “SuperGlue: Learning Feature Matching With Graph Neural Networks”. en. En: IEEE, Seattle, WA, USA, (jun. de 2020), 4937-4946. ISBN: 978-1-7281-7168-5. doi:10.1109/CVPR42600.2020.00499.
- Florian Schroff, Dmitry Kalenichenko y James Philbin. 2015. “FaceNet: A Unified Embedding for Face Recognition and Clustering”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Boston, MA, USA, 815-823. doi:10.1109/CVPR.2015.7298682.
- Kim Senger, Simon J. Buckley, Peter Betlem et al.. 2022. “Svalbox: a portal for sharing digital outcrop models and geoscientific data from Svalbard”. *Earth System Science Data*, 14, 3275-3298.
- Yifan Sun, Changmao Cheng, Yuhang Zhang, Chi Zhang, Liang Zheng, Zhongdao Wang y Yichen Wei. Jun. de 2020. “Circle Loss: A Unified Perspective of Pair Similarity Optimization”. en. En: *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, Seattle, WA, USA, (jun. de 2020), 6397-6406. ISBN: 978-1-7281-7168-5. doi:10.1109/CVPR42600.2020.00643.
- Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E. Sarma, Michael M. Bronstein y Justin M. Solomon. Oct. de 2019. “Dynamic Graph CNN for Learning on Point Clouds”. en. *ACM Transactions on Graphics*, 38, 5, (oct. de 2019), 1-12. doi:10.1145/3326362.
- Kai Xu, M. Li, R. Yi, C. Zhu y Y. Guo. 2025. “2D3D-MATR: 2D-3D Matching Transformer for Detection-free Registration between Images and Point Clouds”. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. Extended Version.
- Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille y Wenqing Tao. 2022. “iBOT: Masked Image Modeling with Self-Distillation”. En: *International Conference on Learning Representations*.